系统架构设计文档

一个可信服务端，把心意稳稳送到。

让心意，送得刚刚好

本文说明 GiftWise AI 的整体架构：由哪些部分组成、为什么这样拆分，以及它如何承载当前的负载、管理状态、扩缩容和从故障中恢复。



公网单实例 `http://117.50.83.57/`

Compshare · Nginx · systemd · 仅 HTTP

目录

02 一页读懂：四个问题的答案 概览
03 架构总览：组件与边界 结构
04 为什么这样设计 取舍
05 一次请求的生命周期 流程
06 负载：时间花在哪、闸门在哪 负载
07 状态管理：什么在哪里、活多久 状态
08 扩缩容：从单实例到多实例 伸缩
09 故障恢复：每类故障怎么接住 韧性
10 可观测、安全与演进 运维

一页读懂

四个问题，四个答案。

GiftWise 是一个“模型负责理解与表达、代码负责把关、用户负责决定”的送礼决策助手。架构围绕这条分工展开。

一个可信服务端
密钥、状态、校验与修订额度全部只在服务端

生成与校验分开
模型出方案，独立代码逐项检查，最多修订一次

慢任务异步化
文字先到，效果图后台生成、原位补上

当前负载怎么承载？

负载

负载是等待型的：时间几乎都花在上游模型上，本机 CPU 很轻。

- Compshare 单实例：Nginx :80 反代到 Node 单进程，systemd 守护
- 请求体 256 KB、有界检索队列、单次模型尝试 120 s 等闸门
- 只为选中的方案生成 1 张图，控制最贵的调用

→ 详见 05 · 06

状态放在哪里？

状态

决策流程在内存，产物与账本独立落盘，浏览器只持签名会话。

- 运行、排除分析、选择与会话签名在内存，重启后旧流程失效
- SQLite、文字缓存、媒体、审计与账本落到 /var/lib/giftwise
- 落盘文件保留，但不能据此恢复旧会话

→ 详见 07

怎么扩缩容？

伸缩

现在是单实例；多副本是后续计划，需先外置状态、签名、幂等与执行归属。

- 公网单实例已跑通一条真实流程，容量未测
- 扩展信号看在途模型调用与排队，而不是 CPU
- 历史规则容器实验不代表全站多副本

→ 详见 08

出故障怎么恢复？

恢复

每类故障都就地接住：可重试的重试，不可重试的明确告知，生图失败不影响文字指南。

- 网络错误有限重试，业务修订全链路最多一次
- 检索受阻时复用合法历史文字；没有可用素材就如实返回
- 重启后不自动重发生图，任务标为“执行未知”

→ 详见 09

39.391 s
【实测·公网单样本】三个可选方案返回

12.797 s
【实测·公网单样本】选定后文字先返回

10.960 s
【实测·公网单样本】后台生图 2304×1728

0.35 元
【推算】典型任务预算 · 100 次约 35.22 元

三段分别计时，不相加为端到端，不推断 P95 【推算】为预算，不是账单实付 【实测·隔离fixture】Node 峰值 86.54 MiB，8/8 用例

架构总览

三层结构，一条可信边界。

浏览器只负责对话、展示与选择；判断和状态都在 Compshare 上的可信服务端；模型、检索、生图和存储在它之下按需调用。

① 浏览器 · 不可信区

桌面与手机同一套页面，不持有密钥与可信状态

- **和小礼聊** 说出需求
- **确认避开** 排除项澄清
- **看三个方案** 理由与依据
- **亲手选定** 只能选通过的
- **读指南** 效果图原位补入

↓ HTTP :80 · http://117.50.83.57/ · JSON · 签名会话 Cookie（未配置 HTTPS）

② 可信服务端 · Compshare Ubuntu 22.04.4 单实例

部署 19b6819

Nginx 公网 :80 → Node v24.16.0 127.0.0.1:8787 · 单进程 · 内置模块 · systemd 守护与自动重启

- **路由与会话** HMAC 签名会话、请求体上限、统一中文错误
- **需求解析** 原话映射为固定字段，缺失时追问
- **排除项分析** 识别并确认“不要什么”
- **推荐编排** 三个可选方案 · 模型调用检索工具取公开文字
- **独立校验** 预算、禁忌、结构逐项检查；时间不影响可选性
- **修订控制** 全链路业务修订最多 1 次
- **选后呈现** 明确选择后生成指南并复核，文字先返回
- **媒体任务** 后台生图 pending→ready / failed / unknown
- **检索工作队列** 有界队列与超时；匿名 HTTP 公开文字
- **运行快照** 候选、校验、修订计数、选择（内存）
- **账本与审计** 模型调用、工具调用、媒体记录
- **同源媒体读取** 只读 GET 任务与图片，校验会话归属

↓ 按需调用 · 外部模型与生图 API 走 HTTPS · 密钥只在服务端

③ 外部能力

- **文字模型 API · HTTPS** 解析、三个方案、修订、赠送指南
- **公开文字检索 · 匿名 HTTP** 真实公开文字 + 合法历史摘要（保留观察时间）
- **Seedream API · HTTPS** 仅在用户明确选择后生成 1 张效果图

④ 本地存储

- **进程内存** 运行 · 排除分析 · 选择 · 会话签名；重启旧流程失效
- **/var/lib/giftwise/runtime** 文字缓存 · 媒体任务与图片 · 审计 · LLM 账本
- **/var/lib/giftwise/db** 独立 SQLite，不用演示库；商品读取为兼容能力

生成阶段（模型参与） 确定性代码 选后阶段

运维通道 OpenCLI 用于部署操作，不在用户请求链路中

模型在下面干活，
代码在中间把关

为什么这样设计

每个选择，都换来一样东西。

下面六个关键决定，逐条写清我们选了什么、为什么选、付出了什么代价。

	选择	理由	代价
01	单一可信服务端：Node.js 24 单进程，Nginx 反代、systemd 守护	业务是“等模型”的 I/O 型负载，异步单进程即可承载当前使用；只用内置模块，部署只需 Node + Nginx + systemd，不引入 Docker / K8s，密钥只有一个落点。	单点运行；流程状态在进程内存，横向扩展前需要先外置（见 08）。
02	生成、检查、决定三件事分开	模型不给自己打分：预算、禁忌、结构交给独立代码；用户只能在通过检查的方案里选，选择权始终在人。	多一道校验与可能的一次修订，换来结果可预期。
03	全链路业务修订最多 1 次，输出格式重试最多 1 次	把最坏情况的调用次数和耗时封顶，成本与等待都可预测，不会陷入“越修越多”的循环。	极少数情况一次修不好，就明确告知，不硬凑结果。
04	选定后才生图，且异步：文字先返回	出图是最慢、最贵的一步。只为选中的方案生成一张；指南复核通过即返回，效果图在后台生成、原位补上，读指南不用等图。	需要任务状态与幂等机制：状态刷新只读，不会重新付费。
05	推荐有据：模型调用检索工具，真实素材先进入模型	查什么由模型结合上下文决定；服务端用 HTTP 获取公开文字素材并复用来源缓存，同一批素材可支撑多个思路，减少重复检索。	多一轮工具往返；没有可用素材或依据无法确认时，如实返回而不硬凑方案。
06	可信状态只留服务端，浏览器只持签名会话	修订计数、候选、选择都不能被前端篡改；任务和图片按会话隔离，他人不可读。	会话密钥随进程生成，重启后需要重新开始一次会话。

一句话 模型负责理解与表达，代码负责把关，用户负责决定；慢的、贵的、会失败的，都放到不挡路的位置。

一次请求的生命周期

从一句话，到一份指南。

一次完整的送礼决策会经过六步。右侧是每一步的调用次数、公网单样本耗时与它写入的状态。

需求解析 模型

用户和小礼聊天，模型把原话映射为固定字段，保留喜好原话；缺的关键信息自然追问。解析失败时用表单原值继续，不卡住用户。

0–1 次
写入：解析审计块（只做交代，不参与校验）

确认要避开的 用户

识别“不要什么”并请用户确认，得到排除分析记录，后续推荐与校验都以它为准。

分析 ID
写入：排除分析（内存，10 分钟）

三个方案 模型 + 工具

模型结合完整上下文生成三个方案；调用检索工具，用匿名 HTTP 获取公开文字并复用合法历史摘要，素材先进入模型，再形成创意。推荐卡不配网络图片。

39.391 s
公网单样本，含一次修订
写入：运行快照、文字缓存

独立校验与一次修订 代码

独立代码逐项检查预算、禁忌、结构；时间只作信息，不影响可选性。有可修问题时让模型修订一次，已通过项受保护。成功时返回三个可选方案。

≤ 1 次
写入：校验结果、修订计数、可选列表

用户选定，生成指南 用户 模型

服务端核对选择属于本会话且在可选列表内，生成贺卡、包装与赠送方式并复核；文字立即返回。纯体验没有实体交付时不输出包装章节。

12.797 s
公网单样本，文字先到
写入：选择、呈现与复核结果

效果图后台生成 异步

以“运行 + 候选 + 计划版本”的哈希为任务 ID 独占创建，后台调用 Seedream 4.5；页面只读查询状态，完成后原位补图，失败不影响文字。

10.960 s
1 张 2304×1728，无参考图输入
写入：任务文件、图片文件

【实测·公网单样本】从结构化输入开始，文本模型 5 次、29,513 tokens；三段分别计时，不相加为端到端　【推算】典型任务约 0.35 元

负载

时间花在等待上，闸门守在入口。

GiftWise 的负载是“少量请求、长时间等待上游”。因此架构的重点不是算力，而是控制并发、超时和最贵的调用。

一次典型任务的预算 推算

ModelVerse 刊例：文本输入 2 元 / 输出 8 元每百万 tokens，Seedream 4.5 每张 0.25 元

文本 7 次	0.102 元	25,763 入 / 6,334 出
效果图 1 张	0.25 元 · 仅为选中方案生成	
合计	0.352 元 / 次 · 100 次约 35.22 元	

【实测·隔离fixture】Node 峰值工作集 86.54 MiB；并发 2 的 20/20 mock 任务完成；异步、幂等与会话隔离等 8/8 用例通过

负载的性质



耗时主要是模型推理与检索的网络等待，服务端异步处理。部署机购买配置为 8 核 / 64 GB / P40，模型与生图走远端 API，配置不代表实耗；公网单样本不推断吞吐或 P95。

入口与上游的闸门

256 KB
请求体上限，超出立即拒绝

4 / 3 并行
有界检索队列；不等于全站硬并发容量

120 s
单次模型尝试；前端普通 120 s、解析 60 s，Nginx 读 900 s，分别设置，不是统一 SLA

⩽ 2 次
网络重试，硬上限 3；线性退避 250 ms 递增

200 条
运行快照上限，超出淘汰最旧，10 分钟过期

1 张
每次选择只生成一张图；生图默认关闭，需显式开启

断开取消
推荐阶段取消在途模型与检索；解析、呈现与后台图不保证随退出停止

调用预算
可配置调用计数上限，默认未设；不是严格费用封顶

控制手段

- ✓ 重复提交同一请求命中幂等键，不会再跑一遍生成
- ✓ 素材缓存复用同批真实资料，减少重复检索
- ✓ 修订封顶，最坏情况的调用次数可算
- ✓ 所有阈值集中在配置层，可按环境变量调整

状态管理

按寿命分层，按会话隔离。

每一份状态都回答三个问题：放在哪里、活多久、重启之后还在不在。流程状态在内存，产物在独立目录；文件还在，不等于旧会话还能读取。

热 · 进程内存
运行、排除分析、选择与会话签名：快、可淘汰；重启后旧流程失效。

温 · /var/lib/giftwise/runtime
文字缓存、媒体任务与图片、审计、LLM 账本：独立落盘，文件跨重启保留。

独立 · /var/lib/giftwise/db
本次独立 SQLite，启动器建表；不使用、不写原演示库。

状态	放在哪里	生命周期与上限	一致性手段	重启后
会话身份	浏览器 Cookie（HttpOnly · SameSite=Strict）	随浏览器会话；签名密钥由进程随机生成	HMAC-SHA256 签名，恒定时间比较	重新签发
推荐运行快照	内存 Map	10 分钟过期，最多 200 条，淘汰最旧	候选、校验、修订计数只在服务端；选择须命中可选列表	重新推荐
排除项分析	内存 Map	10 分钟过期，最多 200 条	绑定会话；推荐时校验归属	重新确认
选择与呈现缓存	运行快照内	随运行快照	同一选择重复点击返回同一份结果	随快照
生图任务	runtime `tasks/<id>.json`	长期保留	ID = sha256(运行，候选，计划版本)；独占创建，临时文件 + 重命名	文件保留 *
效果图	runtime `assets/<sha256>`	长期保留	内容寻址；读取时重算哈希，不一致即拒绝	文件保留 *
素材缓存	runtime 文件	最多 80 条，7 天过期	按来源去重，写入前脱敏，保留观察时间	保留
模型调用账本	runtime JSONL	长期保留	逐行追加（非事务）；测试进程自动改道	保留
独立数据库	db 目录 SQLite（node:sqlite）	本次部署新建	启动器建表；在线备份 integrity_check=ok	保留

* 图片与任务文件留在磁盘，但读取仍要求内存中的运行与会话归属；重启后旧流程失效，重启恢复未验收。runtime 备份为同盘逐文件复制，非事务、未异地。

可信状态不出服务端
浏览器提交修订计数等派生字段会被直接拒绝，只能提交需求与“选哪一个”。

按会话隔离
运行快照、生图任务、图片读取都校验会话归属，别人的任务一律 404。

花钱的落盘
生图任务先落盘再执行；重启后未完成的任务标“执行未知”，不自动重发。

扩缩容

先纵向，再横向，一级一级上。

现在是 Compshare 单实例，已跑通一条公网真实流程，容量未测。L1–L3 是计划，尚未实现；每一级都要先完成共享状态、签名、幂等与执行归属的复核，才能声明安全。

每一级只改必须改的 ↗

从这里出发 ↓

L0 · 现在

单实例 · 已部署

- Compshare · Nginx · systemd
- Node 单进程异步 I/O
- 流程在内存，产物独立落盘

现状：一条公网流程已验收，容量未测

L1 · 计划

多实例 · 会话粘滞

- 负载均衡按会话 Cookie 粘滞
- 会话签名密钥改为共享配置
- 媒体文件挂共享卷

触发：在途模型调用长期接近配额上限

L2 · 计划

状态外置 · 无状态

- 运行、排除分析、选择放入带 TTL 的共享存储
- 签名密钥共享；媒体任务条件写入与执行归属
- 原子费用控制后，任意副本接任意请求

触发：需要滚动发布不中断、重启不丢会话

L3 · 计划

弹性伸缩 · 队列解耦

- 生图与检索进任务队列，独立工作者
- 按排队深度与在途调用数扩缩
- 模型调用走统一限流

触发：峰值明显、生图排队超过分钟级

历史参考 · 规则校验容器本地双副本

60 / 60 轮询分发全部通过，两副本各承担一半	**≈ 20 MiB** 单副本常驻内存
0.668 s 容器冷启动到健康检查通过	**5.97 s** 副本下线后被健康检查发现并摘除

出自 2026-10-31 独立 Python 规则 API 的本地实验，不代表当前全站云端多副本。

扩缩信号怎么选

- ✓ **看在途模型调用与排队深度**：这才是用户等待的来源
- ✓ **不以 CPU 为主信号**：等待型负载下 CPU 长期偏低
- ✓ **缩容先排空**：等在途请求与生图任务完成再下线

故障恢复

每一类故障，都有接住它的地方。

按“怎么发现 → 怎么处理 → 用户看到什么”逐条排开。原则：可重试的有限重试，不可重试的明确告知，生图失败不挡文字指南。systemd 自动重启已配置；故障注入、重启恢复与回滚演练未测。

故障	怎么发现	怎么处理	用户看到
上游模型			
超时 / 限流 / 5xx	120 s 超时；状态码 408 409 425 429 5xx	最多重试 2 次，线性退避；仍失败返回明确错误码	中文提示，可直接重试
输出不合法	严格 JSON 解析与结构校验	格式重试最多 1 次；截断或推理耗尽直接停止	明确失败，不展示残缺结果
违反预算或禁忌	独立代码逐项校验	业务修订 1 次，已通过项保护；仍不通过则不进入可选列表	只看到通过检查的方案
检索与外部资料			
来源受限 / 超时 / 队列满	队列超时与上限；受限来源自动暂停	模型换来源再查一轮，复用合法历史文字	有合法素材且模型确认依据时继续
没有可用依据	无可用素材，或模型不确认依据	返回 RETRIEVAL_NO_MATERIAL / BASIS_UNCONFIRMED，不凭空生成	简短提示，稍后再试
效果图			
生图失败 / 超时	任务状态变为 failed / unknown	文字指南不受影响；状态刷新只读，unknown 不盲目重发；重新生成是另一次付费调用	指南可读，图位显示当前状态
刷新 / 重复点击	任务 ID 由运行与候选确定	独占创建命中已有任务；状态查询只读	同一张图，不重复付费
图片文件损坏	读取时重算 sha256	哈希不一致即拒绝返回	不展示错误图片
进程与连接			
进程重启	systemd 拉起新进程；任务记录的执行实例与当前进程不同	未完成的生图任务标为“执行未知”，不自动重发；内存中的流程清空	需重新开始一次推荐
用户中途离开	连接关闭事件	推荐阶段取消在途模型与检索；解析、排除分析、呈现与后台图不保证随之停止	部分阶段仍可能计费
未预期异常	顶层异常捕获	返回 500，不暴露堆栈，不记录密钥	“服务暂时不可用”

有限重试
每一层都有上限

推荐有据
素材先进模型；生图不挡文字

不重复付费
宁可标“未知”，不盲目重试

可观测、安全与演进

看得见，守得住，走得远。

运行时留下可回查的记录，边界上只开必要的口子，下一步沿着扩展路径往前走。

模型调用账本

每次真实调用一行：用途、模型、耗时、HTTP 状态、重试次数、token 用量。不记密钥与提示词正文。

媒体与工具记录

生图任务、产物与内容哈希；检索工具调用写入脱敏审计，可按运行回查。

运行状态与日志

`/healthz` 返回模式、运行数与进程自证；journald 与 Nginx 访问日志留存运行记录。

安全边界

- ✓ 模型与生图密钥只在服务端环境变量，从不写入响应或日志
- ✓ 任务、图片按会话校验归属，越权读取一律 404
- ✓ 前端提交的派生字段直接拒绝，校验只信服务端数据
- ✓ 会话 Cookie 签名、HttpOnly、SameSite=Strict
- ✓ 图片与媒体路由附带 CSP 与 nosniff（按路由设置）
- ✓ 公网入口为 HTTP，未配置 HTTPS；外部模型与生图 API 走 HTTPS

Compshare 单实例
Ubuntu 22.04.4 · Nginx · systemd · 部署 19b6819

0.38 元/小时
【推算】两天约 18.24 元；供应商实付未测

备份
在线 SQLite integrity_check=ok；runtime 同盘非事务归档

2026-11-03 05:11
北京时间平台定时关机，网站随之停止

→ 下一步

01

恢复与回滚

做重启恢复与实际版本回滚演练；状态外置后再评估多副本。

02

容量与稳定性

压测与长时运行，测出单实例容量、真实端到端延迟分布。

03

实付核验与 HTTPS

用供应商账单校准预算；配置域名与 TLS。

回到开头的四个问题

负 负载
等待型负载，异步单进程 + 入口闸门，最贵的调用只做一次。

状 状态
流程在内存、产物独立落盘；可信状态不出服务端。

伸 扩缩容
单实例已在线；多副本需先外置状态、签名与执行归属，属于计划。

复 故障恢复
有限重试、推荐有据、生图独立，宁标未知也不重复付费。

准备礼物的人，先感到幸福。