系统架构设计文档

一个可信服务端，把心意稳稳送到。

让心意，送得刚刚好

本文说明 GiftWise AI 的整体架构：由哪些部分组成、为什么这样拆分，以及它如何承载当前的负载、管理状态、扩缩容和从故障中恢复。



目录

02 一页读懂：四个问题的答案 概览
03 架构总览：组件与边界 结构
04 为什么这样设计 取舍
05 一次请求的生命周期 流程
06 负载：时间花在哪、闸门在哪 负载
07 状态管理：什么在哪里、活多久 状态
08 扩缩容：从单实例到多实例 伸缩
09 故障恢复：每类故障怎么接住 韧性
10 可观测、安全与演进 运维

一页读懂

四个问题，四个答案。

GiftWise 是一个“模型负责理解与表达、代码负责把关、用户负责决定”的送礼决策助手。架构围绕这条分工展开。

一个可信服务端
密钥、状态、校验与修订额度全部只在服务端

生成与校验分开
模型出方案，独立代码逐项检查，最多修订一次

慢任务异步化
文字先到，效果图后台生成、原位补上

当前负载怎么承载？

负载

【实测】并发2的隔离fixture可运行；真实模型吞吐与云端容量仍未测。

- 单进程异步 I/O，等待模型时不占线程
- 请求体 256 KB、检索队列 4、模型超时 120 s 等闸门挡住过载
- 只为选中的方案生成 1 张图，控制最贵的调用

→ 详见 05 · 06

状态放在哪里？

状态

按寿命分三层：热在内存，温落文件，只读数据单独存。

- 推荐运行快照：内存，10 分钟有效，最多 200 条
- 生图任务与图片：文件，原子写、内容寻址
- 浏览器只持有签名会话，不持有任何可信状态

→ 详见 07

怎么扩缩容？

伸缩

先纵向、后横向：把会话与快照外置后，服务端即可无状态多副本。

- 单实例规格需复测，不以mock承诺容量
- 扩展信号看在途模型调用数与排队，而不是 CPU
- 无状态校验服务已做本地双副本实测

→ 详见 08

出故障怎么恢复？

恢复

每类故障都就地接住：可重试的重试，不可重试的明确告知，增强失败不阻断主流程。

- 网络错误有限重试，业务修订全链路最多一次
- 检索失败降级为纯模型建议，推荐照常给出
- 重启后不重复付费生图，任务状态如实标记

→ 详见 09

0.35元	86.54MiB	8/8	20/20
典型任务预算，实付未测	Node峰值，隔离fixture	异步与幂等受控用例	并发2，mock HTTP任务

架构总览

三层结构，一条可信边界。

浏览器只负责对话、展示与选择；所有判断和状态都在可信服务端；模型、检索、生图和存储在它之下按需调用。

① 浏览器 · 不可信区

桌面与手机同一套页面，不持有密钥与可信状态

- **和小礼聊** — 说出需求
- **确认避开** — 排除项澄清
- **看三个思路** — 理由与参考价
- **亲手选定** — 只能选通过的
- **读指南** — 效果图原位补入

↓ HTTPS · JSON · 签名会话 Cookie

② 可信服务端 · Node.js 24 单进程

只用内置模块，零第三方依赖

- **路由与会话** — HMAC 签名会话、请求体上限、统一中文错误
- **需求解析** — 原话映射为固定字段，缺失时追问
- **排除项分析** — 识别并确认“不要什么”
- **推荐编排** — 三个思路 · 模型按需调用检索工具
- **独立校验** — 预算、禁忌、结构逐项检查
- **修订控制** — 全链路业务修订最多 1 次
- **选后呈现** — 贺卡、包装、赠送方式 + 复核
- **媒体任务** — 异步生图、幂等、只读状态查询
- **检索工作队列** — 有界队列、超时、失败即降级
- **运行快照** — 候选、校验、修订计数、选择
- **账本与审计** — 模型调用、工具调用、媒体记录
- **图片代理** — 只放行白名单与已校验图片

↓ 按需调用 · 密钥只在服务端环境变量

③ 外部能力

- **大模型（OpenAI 兼容接口）** — 解析、三个思路、修订、赠送指南
- **公开检索 · OpenCLI** — 灵感、做法、体验与参考资料
- **Seedream 4.5** — 选定后生成 1 张包装效果图

④ 本地存储

- **进程内存** — 运行快照 · 排除分析 · 会话密钥
- **文件** — 媒体任务与图片 · 素材缓存 · 调用账本
- **SQLite（只读）** — 本地商品库，有匹配时增强候选

生成阶段（模型参与）　确定性代码　选后阶段

模型在下面干活，
代码在中间把关

为什么这样设计

每个选择，都换来一样东西。

下面六个关键决定，逐条写清我们选了什么、为什么选、付出了什么代价。

	选择	理由	代价
01	单一可信服务端，Node.js 24 单进程，只用内置模块	业务是“等模型”的 I/O 型负载，异步单进程足够；零依赖意味着一条命令启动、没有供应链风险，密钥只有一个落点。	单点运行；状态在进程里，横向扩展前需要先外置（见 08）。
02	生成、检查、决定三件事分开	模型不给自己打分：预算、禁忌、结构交给独立代码；用户只能在通过检查的方案里选，选择权始终在人。	多一道校验与可能的一次修订，换来结果可预期。
03	全链路业务修订最多 1 次，输出格式重试最多 1 次	业务修订与格式重试有界；工具轮次、传输尝试另计。费用和等待仍需总预算。	极少数情况一次修不好，就明确告知，不硬凑结果。
04	选定后才生图，且异步：文字先返回	选定后文字先返回，图片在后台生成。隔离用例已验证异步与幂等；真实成功图延迟尚未测，不能承诺秒数。	需要一套任务状态与幂等机制，防止刷新重复付费。
05	检索是增强，不是前提；由模型按需调用	需要具体资料时才查，不必每次全平台先抓；来源受限时降级为纯模型建议，推荐不会因此失败。	检索结果的丰富程度随来源可用性波动。
06	可信状态只留服务端，浏览器只持签名会话	修订计数、候选、选择都不能被前端篡改；任务和图片按会话隔离，他人不可读。	会话密钥随进程生成，重启后需要重新开始一次会话。

一句话 模型负责理解与表达，代码负责把关，用户负责决定；慢的、贵的、会失败的，都放到不挡路的位置。

一次请求的生命周期

从一句话，到一份指南。

各阶段按实际路径计费；真实完整端到端与成功图延迟尚未测定。

需求解析 模型

用户和小礼聊天，模型把原话映射为固定字段，保留喜好原话；缺的关键信息自然追问。解析失败时用表单原值继续，不卡住用户。

真实未测

写入：解析审计块（只做交代，不参与校验）

确认要避开的 用户

识别“不要什么”并请用户确认，得到排除分析记录，后续推荐与校验都以它为准。

分析 ID

写入：排除分析（内存，10 分钟）

三个思路 模型 + 工具

模型结合完整上下文生成三个思路；需要外部资料时调用检索工具，真实素材先进入模型，再形成创意。本地商品库有匹配时一并增强。

真实未测

含检索与校验

写入：运行快照、素材缓存

独立校验与一次修订 代码

独立代码逐项检查预算、禁忌、结构；有可修问题时让模型修订一次，已通过项受保护。只有通过的候选进入可选列表。

≤ 1 次

写入：校验结果、修订计数、可选列表

用户选定，生成指南 用户 模型

服务端核对选择属于本会话且在可选列表内，生成贺卡、包装与赠送方式并复核；文字立即返回。重复点击命中幂等缓存。

文字先到

写入：选择、呈现与复核结果

效果图后台生成 异步

以“运行 + 候选 + 计划版本”的哈希为任务 ID 独占创建，后台调用 Seedream 4.5；页面只读查询状态，完成后原位补图，失败不影响文字。

后台生成
成功图延迟未测

写入：任务文件、图片文件

【推算】约0.35元/任务 · 【fixture实测】峰值86.54MiB

负载

时间花在等待上，闸门守在入口。

GiftWise 的负载是“少量请求、长时间等待上游”。因此架构的重点不是算力，而是控制并发、超时和最贵的调用。

当前成本与隔离检测

【推算】典型任务约0.35元，100次约35元

【实测·fixture】Node峰值86.54MiB

【实测·fixture】20/20 mock任务；8/8用例

【未测】实付、真实完整E2E与云端容量

负载的性质



当前隔离测量仅覆盖本地编排与存储。
真实模型吞吐、长时负载与目标云机未测；
不能由短时mock测试承诺单实例容量。

入口与上游的闸门

256 KB
请求体上限，超出立即拒绝

4 / 3 并行
检索队列上限；公开 HTTP 最多 3 路并行，浏览器类独占

120 s
每次尝试120秒；
前端可能先超时；
总时限尚未统一。

⩽ 2 次
网络重试，硬上限 3；线性退避 250 ms 递增

200 条
运行快照上限，超出淘汰最旧，10 分钟过期

1 张
每次选择只生成一张图；生图默认关闭，需显式开启

取消需贯穿
部分路径传播取消信号；
关页不等于停止计费。

调用预算
预算默认未设；按invoke计数，不是物理尝试费用锁。并发原子预留仍需补齐。

容量与费用仍待复验

- ✓ 重复提交同一请求命中幂等键，不会再跑一遍生成
- ✓ 素材缓存复用同批真实资料，减少重复检索
- ✓ 业务修订有界，总费用按实际attempt预留；配置阈值不等于统一总deadline。

状态管理

按寿命分层，按会话隔离。

每一份状态都回答三个问题：放在哪里、活多久、重启之后还在不在。

热 · 进程内存
决策过程中的短期状态：快、可淘汰、随会话结束而过期。

温 · 项目内文件
花过钱或需要回查的产物：原子写入、可跨重启保留。

只读 · 数据库
商品库只读打开；服务端从不写共享数据。

状态	放在哪里	生命周期与上限	一致性手段	重启后
会话身份	浏览器 Cookie（HttpOnly · SameSite=Strict）	随浏览器会话；签名密钥由进程随机生成	HMAC-SHA256 签名，恒定时间比较	重新签发
推荐运行快照	内存 Map	10 分钟过期，最多 200 条，淘汰最旧	候选、校验、修订计数只在服务端；选择须命中可选列表	重新推荐
排除项分析	内存 Map	10 分钟过期，最多 200 条	绑定会话；推荐时校验归属	重新确认
选择与呈现缓存	运行快照内	随运行快照	同一选择重复点击返回同一份结果	随快照
生图任务	文件 `tasks/<id>.json`	长期保留	ID = sha256(运行，候选，计划版本)；独占创建，临时文件 + 重命名原子写	保留
效果图	文件 `assets/<sha256>`	长期保留	内容寻址；读取时重算哈希，不一致即拒绝	保留
素材缓存	项目内文件	最多 80 条，7 天过期	按来源去重，写入前脱敏	保留
模型调用账本	JSONL 追加	长期保留	只追加；测试进程自动改道，不碰真实账本	保留
本地商品库	SQLite（node:sqlite）	由采集侧维护	服务端只读打开	保留

可信状态不出服务端
浏览器提交修订计数等派生字段会被直接拒绝，只能提交需求与“选哪一个”。

按会话隔离
运行快照、生图任务、图片读取都校验会话归属，别人的任务一律 404。

花钱的落盘
生图任务先落盘再执行，跨重启可查，避免同一选择重复付费。

扩缩容

先纵向，再横向，一级一级上。

当前阶段单实例足以承载演示与小规模使用。扩展路径按“什么时候需要”排好顺序，每一级只做那一级必须的改变。

每一级只改必须改的 ↗

从这里出发 ↓

L0 · 现在

单实例 · 纵向

- Node 单进程异步 I/O
- 状态在内存 + 项目内文件
- 闸门控制并发与超时

够用的原因：瓶颈在上游模型配额，不在 CPU

L1

多实例 · 会话粘滞

- 负载均衡按会话 Cookie 粘滞
- 会话签名密钥改为共享配置
- 媒体文件挂共享卷

触发：在途模型调用长期接近配额上限

L2

状态外置 · 无状态

- 运行快照、排除分析放入带 TTL 的 KV
- 媒体任务进对象存储；独占创建对应条件写入
- 任意副本可接任意请求

触发：需要滚动发布不中断、重启不丢会话

L3

弹性伸缩 · 队列解耦

- 生图与检索进任务队列，独立工作者
- 按排队深度与在途调用数扩缩
- 模型调用走统一限流

触发：峰值明显、生图排队超过分钟级

无状态校验服务 · 本地双副本实测

60 / 60 轮询分发全部通过，两副本各承担一半	**≈ 20 MiB** 单副本常驻内存
0.668 s 容器冷启动到健康检查通过	**5.97 s** 副本下线后被健康检查发现并摘除

扩缩信号怎么选

- ✓ **看在途模型调用与排队深度**：这才是用户等待的来源
- ✓ **不以 CPU 为主信号**：等待型负载下 CPU 长期偏低
- ✓ **缩容先排空**：等在途请求与生图任务完成再下线

故障恢复

每一类故障，都有接住它的地方。

按“怎么发现 → 怎么处理 → 用户看到什么”逐条排开。原则：可重试的有限重试，不可重试的明确告知，增强失败不挡主流程。

故障	怎么发现	怎么处理	用户看到
上游模型			
超时 / 限流 / 5xx	120 s 超时；状态码 408 409 425 429 5xx	最多重试 2 次，线性退避；仍失败返回明确错误码	中文提示，可直接重试
输出不合法	严格 JSON 解析与结构校验	格式重试最多 1 次；截断或推理耗尽直接停止	明确失败，不展示残缺结果
违反预算或禁忌	独立代码逐项校验	业务修订 1 次，已通过项保护；仍不通过则不进入可选列表	只看到通过检查的方案
检索与外部资料			
来源受限 / 超时	工作队列超时与异常捕获	降级为“仅增强”，模型直接给出建议	推荐照常给出
队列已满	队列长度达到 4	新检索立即拒绝并降级，不排长队	推荐照常给出
效果图			
生图失败 / 超时	任务状态变为失败	文字指南不受影响；提供简洁重试入口	指南可读，图位显示可重试
刷新 / 重复点击	任务 ID 由运行与候选确定	独占创建命中已有任务；状态查询只读	同一张图，不重复付费
图片文件损坏	读取时重算 sha256	哈希不一致即拒绝返回	不展示错误图片
进程与连接			
进程重启	任务记录的执行实例与当前进程不同	未完成的生图任务标为“执行未知”，不自动重试；内存快照清空	需重新开始一次推荐
用户中途离开	连接关闭事件	取消在途的模型与检索调用	不再消耗额度
未预期异常	顶层异常捕获	返回 500，不暴露堆栈，不记录密钥	“服务暂时不可用”

有限重试
每一层都有上限

增强可降级
检索、图片都不挡主流程

不重复付费
宁可标“未知”，不盲目重试

可观测、安全与演进

看得见，守得住，走得远。

运行时留下可回查的记录，边界上只开必要的口子，下一步沿着扩展路径往前走。

模型调用账本

每次真实调用一行：用途、模型、耗时、HTTP 状态、重试次数、token 用量。不记密钥与提示词正文。

媒体与工具记录

生图任务、产物与内容哈希；检索工具调用写入脱敏审计，可按运行回查。

运行状态

`/healthz` 返回模式、当前运行数与进程自证（进程 ID、代码版本、启动时间）。

安全边界

- ✓ 模型与生图密钥只在服务端环境变量，从不写入响应或日志
- ✓ 任务、图片按会话校验归属，越权读取一律 404
- ✓ 前端提交的派生字段直接拒绝，校验只信服务端数据
- ✓ 会话 Cookie 签名、HttpOnly、SameSite=Strict
- ✓ 图片代理只放行白名单与已校验内容，附带 CSP 与 nosniff
- ✓ 生图默认关闭，部署方显式开启后才会产生费用

→ 下一步

01

状态外置

运行快照进带 TTL 的 KV，媒体进对象存储，支持重启恢复与多副本。

02

官方商品数据

接入电商官方 API，绑定真实商品与价格条件，替代公开资料。

03

上云与成本

刊例预算已核实，实付待对账。
补总deadline、并发与留存。

回到开头的四个问题

负载
选定后才生图，按实际尝试计费；
单实例容量仍待复验。

状
状态
热在内存、温落文件、只读单列；可信状态不出服务端。

伸
扩缩容
先纵向再横向；外置会话与快照后即可无状态多副本。

复
故障恢复
有限重试、增强可降级、宁标未知也不重复付费。

准备礼物的人，先感到幸福。